

Dossier Strategique IA Neoteem

NeoChat, NeoMail, NeoDoc :
Le capital technique est la.
Les conditions pour le livrer ne le sont pas.


Diagnostic complet, benchmark concurrentiel, analyse des blocages,
couts reels, avis strategiques et recommandations.

Auteurs	Raphael PICARD & Jerome
Date	Mai 2026 — Version finale
Destinataires	Direction Neoteem
Classification	Interne — Confidentiel — Strategique

Sommaire

1. Synthèse executive
2. Ce qui a été construit : l'inventaire factuel
3. Ce qui est en production client : le constat
4. Pourquoi rien ne sort : les 8 blocages identifiés
5. Benchmark concurrentiel : avec qui on se compare
6. La menace Gemini dans Gmail
7. Le piège de 'recréer Gmail' — avis critique
8. Le coût réel des économies
9. Les deux options stratégiques
10. L'équipe nécessaire et la reorganisation
11. Modèle économique : comment faire payer les clients
12. Grille de prix complète — comparatif modèles IA
13. Coûts détaillés par produit (NeoMail, NeoChat, NeoDoc)
14. Recommandations et plan d'action
15. Verdict final de Claude : Option A vs Option B

1. Synthèse executive



En 6 mois, 2 personnes (Raphael et Jerome) ont construit : 3 applications IA (NeoChat, NeoMail, NeoDoc), 3 MCP custom deployes, un vault de 682+ notes de connaissance metier, et des outils de productivite pour le support et la direction. C'est un volume de travail qui correspond a une equipe de 4-5 personnes.

Aucun de ces produits n'est en production client.

NeoChat est en pilote depuis 5 mois sans utilite confirmee. NeoMail n'a pas de front. NeoDoc est en cours. Pendant ce temps, Bellman (groupe Septeo, 3 000 employes) repond a 70% des emails syndics en 1 clic. Genius Immo (10 personnes) a son chatbot et son agent mail en production a 49 EUR/mois par utilisateur. Gemini est integre nativement dans le Gmail que tous nos clients utilisent.

Avis Claude : Le diagnostic est clair : le capital technique existe et il est impressionnant pour 2 personnes. Mais un capital technique qui ne genere pas de revenu est un cout, pas un actif. Genius Immo, avec 10 personnes et 112K EUR de capital, livre plus vite que Neoteem. Ce n'est pas un probleme de competence — c'est un probleme d'organisation et de priorites. Les 8 blocages identifies dans ce document sont presque tous resolvables a cout zero par de la reorganisation interne.

Le cout de l'inaction

Chaque mois sans produit IA en production, c'est du revenu perdu. A 100-200 EUR/mois par client pour un SaaS IA integre, sur 50 clients potentiels, c'est 5 000 a 10 000 EUR de revenu mensuel qui n'est pas capture — soit 60 000 a 120 000 EUR/an. L'investissement demande pour debloquer la situation est de 82-100K EUR/an. Il se rembourse la premiere annee.

La decision demandee

Reorganiser les ressources internes autour de l'IA. Nommer un Responsable IA dedie avec pouvoir de decision. Prioriser NeoMail — le produit que les clients demandent. Debloquer les acces admin, affecter un UX, proteger du temps QA. La plupart de ces actions sont de la reorganisation a cout zero.

2. Ce qui a ete construit : l'inventaire factuel


En 6 mois, avec 2 personnes, voici ce qui existe :

Composant	Description	Etat
NeoChat (agent conversationnel)	7 agents, 26 tools, Declarative ReAct Engine (~50 lignes vs ~1500 en workflow classique). Adaptive Prompt Builder 4 layers, HybridToolSelector pgvector, 6 interrupt handlers.	Backend OK Front basique En pilote 5 mois
NeoMail (pipeline mail autonome)	Pipeline webhook Pub/Sub > classify LLM > label Gmail > brouillon auto. 21 tools, regle BROUILLON ONLY a 5 niveaux de defense. 9 endpoints API, schema BDD dedie.	Backend OK Pas de front Pas en prod
NeoDoc (RAG documentaire)	Pipeline ingestion 7 etapes (Drive > GCS > Vertex AI). Agent Research 5 noeuds. Grounding citations, multi-tenant. Tests : fail_under=80, DeepEval faithfulness >= 0.8.	Backend OK Tests serieux Pas en prod
3 MCP custom	obsidian-brain v2 (vault 682 notes), JIRA-NEOTEEM (notes internes + copy PJ), feedback-neoteem (boucle Langfuse > Jira). Deployes Cloud Run.	En prod (usage interne)
neoteem-brain (knowledge base)	682+ notes, 2245+ wikilinks. 4 agents maintenance, 5 plugins role-based. Domaines : syndic copro, gerance locative, comptabilite immo.	En prod (usage interne)
Plugins Cowork (productivite equipe)	nils-copilot (brief matin, strategic-advisor). support-lojii-plugin (trriage 3 phases avec retro auto-correctrice). feedback-triage. backlog-hub.	En prod (Nils, Valery, support)

Au total : 3 applications IA, 3 MCP custom, 682+ notes metier, des plugins de productivite — produit par 2 personnes. C'est remarquable.

Avis Claude : Ce volume de travail est exceptionnel pour 2 personnes en 6 mois. Sur le marche Lyon, constituer une equipe equivalente (lead IA + fullstack DevOps + dev + UX) couterait 200-250K EUR/an. Neoteem a obtenu ce capital technique a moindre cout. Le probleme n'est pas la production — c'est la livraison.

3. Ce qui est en production client : le constat



Le travail technique est fait. Les backends fonctionnent. Les tests passent. Mais cote client, rien n'est visible. NeoChat est en pilote depuis 5 mois et les retours indiquent une utilite a confirmer. NeoMail — le produit que les clients demandent le plus — n'a toujours pas de front apres 3+ mois de developpement backend.

Il n'existe aucun KPI produit chiffre : pas de DAU, pas de MAU, pas de NPS, pas de taux d'adoption. Personne ne mesure si ce qu'on construit est utilise.

Les plaintes clients sur les mails sont remonteées au support mais ne sont pas collectees de maniere structuree. On construit des produits sans ecouter formellement les clients.

Avis Claude : L'absence de KPI est un signal d'alarme. Comment savoir si NeoChat est utile sans mesurer son utilisation ? Comment justifier un investissement sans donnees de retour client ? La premiere action du futur Responsable IA devrait etre d'installer des metriques : DAU, MAU, NPS, MRR. Sans mesure, pas de decision eclairee.

4. Pourquoi rien ne sort : les 8 blocages identifiés

1. Pas de responsable IA dédié.

Le responsable actuel supervise l'IA parmi d'autres sujets. Il n'est pas full-time sur l'IA, n'a pas la bande passante pour écouter les clients, arbitrer les priorités, et piloter la livraison. Les choix d'outils (Gemini) et de priorités (NeoChat avant NeoMail) ne correspondent pas aux besoins clients remontés.

2. Pas de maquettes, pas d'UX dédié IA.

Jerome peut développer le front, mais sans maquettes il ne peut pas avancer. Les designers ne sont pas priorisés sur les projets IA. Résultat : NeoMail attend son front depuis 3+ mois.

3. Le DevOps est un goulot d'étranglement.

Quand on demande quelque chose, ça met 3 mois. Jerome a les compétences DevOps mais n'a accès admin que sur l'environnement de développement — pas test, pas production.

4. Les QA sont surchargés.

Les testeurs ont trop de projets à tester et ne peuvent pas consacrer du temps à l'IA. Sans validation QA, aucun produit ne peut passer en production.

5. On ne sait pas ce que les clients veulent.

Les clients se plaignent des mails au support — c'est le pain point numéro un. Mais ces remontées ne sont pas collectées. On a développé un chatbot (NeoChat) en priorité alors que les clients demandent l'automatisation mail.

6. Choix de LLM non optimal.

Gemini a été choisi pour des raisons de coût. Mais le tool calling est moins fiable, la rédaction française est inférieure, et Gemini 3 est en Preview (pas de SLA production). L'économie de ~200 EUR de tokens sur 6 mois coûte des semaines de debug supplémentaires.

7. 2 personnes font le travail de 5.

Raphael et Jerome portent seuls l'ensemble des projets IA. 3 apps, 3 MCP, le brain, les plugins Cowork. Et Raphael produit déjà des skills, un copilot dirigeant, et des formations IA — en plus de sa mission contractuelle.

8. La direction dit 'ça va changer' depuis 3 mois.

Les problèmes sont identifiés. Les solutions sont connues. Mais aucune décision concrète n'a été prise. Chaque mois d'indécision est un mois offert aux concurrents.

Avis Claude : Les blocages 1, 2, 3, 4 et 5 sont résolubles à coût zéro par de la reorganisation interne. Donner à Jerome les accès admin (blocage 3), affecter un UX aux maquettes IA (blocage 2), protéger du temps QA (blocage 4), collecter les besoins clients (blocage 5) — aucune de ces actions ne coûte un euro. Elles ne nécessitent qu'une décision. Le blocage 6 (Gemini) coûte ~30-50 EUR/mois à résoudre en switchant vers Claude/GPT. Seul le blocage 7 (effectif insuffisant) nécessite un vrai investissement.

5. Benchmark concurrentiel : avec qui on se compare

	Bellman (Septeo)	Genius Immo	Reemia (Foncia)	Neoteem
Equipe totale	11-50 + Septeo 3000	~10 personnes	~5 + Emeria	2 dedies IA
Groupe derriere	Septeo 244M\$ CA Bpifrance, Lab IA	Independant 112K EUR capital	Emeria/Foncia Milliers employes	Independant Startup
Chatbot copro	En production	En prod (Genius GPT)	En prod (Sirius)	5 mois pilote utilite a confirmer
IA Email	En prod 70% emails 1 clic	En prod (Office 365)	Non visible	Backend OK pas de front
IA Document	-	Memoire immeuble (production)	Orion IDP 12M+ docs	En cours dev
Formation IA	Webinars reguliers	Oui (revenue stream) Qualiopi	-	Non
LLM utilise	OpenAI (ChatGPT)	OpenAI (ChatGPT)	Multi (LangChain)	Gemini (Preview)
Prix IA client	Inclus dans le logiciel	49 EUR/mois par utilisateur	Inclus dans le service	Pas de produit client

Prix concurrents — benchmark marche

Concurrent	Modele tarifaire	Prix	Exemple 5 gestionnaires
Genius Immo	Abonnement mensuel par utilisateur	49 EUR/mois/utilisateur (Essentiel) Pro sur devis	245 EUR/mois
Bellman (Septeo)	Inclus dans le logiciel	Pas de surcout IA visible	0 EUR surcout
Formations IA marche	Formation intra-entreprise	1 200-3 000 EUR/jour Financable OPCO/Qualiopi	1 500 EUR (1 jour)

Avis Claude : Le constat est sans appel. Genius Immo, avec 10 personnes et 112K EUR de capital, livre plus vite que Neoteem et facture deja 49 EUR/mois par utilisateur. Bellman a acces aux ressources d'un groupe de 3 000 personnes avec un lab IA dedie et Bpifrance au capital. Tous les concurrents utilisent OpenAI (ChatGPT), pas Gemini. C'est un choix pragmatique — le tool calling et la redaction francaise sont meilleurs — pas un choix d'economie. Se comparer a eux sans les moyens correspondants, c'est se condamner a etre toujours en retard. Mais Neoteem a un avantage qu'aucun concurrent ne peut reproduire : l'integration native aux donnees ERP Loji.

6. La menace Gemini dans Gmail

Tous les clients Loji sont sur Google Workspace. Depuis début 2026, Gemini est intégré nativement dans leur Gmail : résumé automatique des fils de mails, Smart Replies contextuelles, Help Me Write, priorisation intelligente. Disponible sur Google Workspace Business et Enterprise — les plans que nos clients ont déjà.

Nos clients ont déjà de l'IA dans leur Gmail, gratuitement, incluse dans leur abonnement Google Workspace. Gemini résume leurs mails, leur suggère des réponses, et rédige des brouillons.

Ce que Gemini dans Gmail ne fait PAS (et que NeoMail pourrait faire) :

- Accéder aux données métier Loji (charges, lots, copropriétaires, historique interventions)
- Classifier les mails par type métier (réclamation, impaye, demande de travaux, AG)
- Générer un brouillon contextualisé avec les vraies données du lot et du copro
- Déclencher des actions métier (créer un ticket intervention, envoyer une relance)

C'est la seule fenêtre de différentiation de NeoMail : le contexte métier. Gemini peut résumer un mail et suggérer une réponse générique. NeoMail peut dire 'c'est M. Dupont, lot 34, il a déjà appelé 3 fois pour cette fuite, le plombier Durand est intervenu le 15 mars sans succès, voici un brouillon avec le numéro de dossier et la prochaine date d'intervention'.

Menace critique — MCP Gemini Enterprise : Google a lancé le support MCP officiel pour tous ses services (Gmail, Drive, Calendar) en Developer Preview. Gemini Enterprise permet déjà de connecter des serveurs MCP custom tiers. Le jour où un client syndic branche le MCP Loji directement sur son Gemini Enterprise, NeoMail n'a plus de raison d'exister comme produit séparé. Ce jour n'est pas dans 2 ans — c'est en Developer Preview maintenant.

Avis Claude : La fenêtre d'opportunité pour NeoMail est étroite et se referme. Chaque mois de retard augmente la probabilité que Gemini + MCP rende l'approche 'produit logiciel mail dans Loji' obsolète. La question stratégique fondamentale : est-ce que NeoMail doit être un produit logiciel ou un service MCP que les clients branchent sur la plateforme de leur choix ? Si produit logiciel : sortir MAINTENANT. Si service MCP : l'option B est peut-être la bonne stratégie. Mais il faut décider maintenant, pas dans 6 mois.

7. Le piege de 'recreer Gmail' — avis critique

Alerte strategique. La direction veut recreer un client mail complet dans Loji — c'est-a-dire reconstruire l'equivalent de Gmail avec la classification IA, les automatisations, l'interface de lecture/envoi/reponse, la gestion des pieces jointes, etc.

Google emploie des milliers d'ingenieurs sur Gmail. Le client mail est l'un des logiciels les plus complexes qui existe : synchronisation temps reel, gestion offline, rendu HTML de mails, securite anti-phishing, spam filtering, gestion de pieces jointes, calendrier integre, contacts, recherche full-text sur des annees d'historique, accessibilite, mobile-responsive...

Vouloir reconstruire ca avec 2-4 personnes, c'est exactement le type de decision qui explique pourquoi rien ne sort en production. Ce n'est pas un avis — c'est une realite technique objective.

La bonne approche (ce que Bellman fait et ca marche) :

- Un add-on Gmail (Google Cards framework, ~200 lignes de code) ou un panneau lateral dans Loji qui s'affiche a cote de Gmail
- Le client ne quitte jamais Gmail — il garde son outil qu'il connait et qu'il aime
- L'IA travaille en arriere-plan : classification, enrichissement contexte Loji, brouillon auto
- Le brouillon apparait dans Gmail — le gestionnaire valide en 1 clic (le modele Bellman : 70% des mails)

Avis Claude : Je le dis sans filtre : recreer Gmail est une erreur strategique majeure. C'est le type de projet qui absorbe 12-18 mois de developpement, ne sera jamais aussi bon que Gmail, et pendant ce temps les concurrents qui ont fait le choix pragmatique (add-on Gmail ou panneau lateral) signent les clients. Bellman l'a compris. Genius l'a compris (ils travaillent avec Office 365, pas un client mail maison). La valeur de NeoMail n'est PAS l'interface mail — c'est le contexte metier Loji. L'interface mail, les clients l'ont deja : c'est Gmail. Il faut l'enrichir, pas le remplacer. Un add-on Gmail + un panneau lateral Loji = 2-3 mois de dev. Un client mail complet = 12-18 mois minimum, et probablement jamais fini.

8. Le cout reel des economies

Trois economies qui coutent plus cher que l'investissement :

Economie 1 : Gemini au lieu de Claude/GPT

Gain : ~200 EUR de tokens sur 6 mois.

Cout reel : tool calling moins fiable, redaction francaise inferieure, modele en Preview sans SLA. Tous les concurrents utilisent OpenAI. Aucun n'utilise Gemini pour les produits clients.

Economie 2 : Skills Cowork au lieu d'agents API custom

Gain : pas de cout de developpement API supplementaire.

Cout reel : les skills grossissent indefiniment, pas de tracing, pas de metriques, limite a 5-25 runs/jour. Le triage de 100+ tickets/jour en skills Cowork coute ~500 EUR/mois d'abonnement pour un service moins fiable que ce qu'un agent API ferait pour ~40-70 EUR/mois en tokens.

Economie 3 : Pas de recrutement / reorganisation IA

Gain : pas de salaire supplementaire.

Cout reel : 3 apps IA construites et 0 en production client. Des mois de developpement qui ne generent aucun revenu. Des concurrents qui signent les clients que Neoteem ne peut pas servir.

Le paradoxe : Neoteem a investi 6 mois de temps de 2 consultants pour construire un capital technique impressionnant. Mais refuse d'investir les 3-4 personnes supplementaires necessaires pour transformer ce capital en revenu. C'est comme construire une usine et refuser d'embaucher les ouvriers pour la faire tourner.

Avis Claude : L'economie Gemini est un mirage : Gemini 2.5 Flash coute 0.30\$/M vs GPT-4.1 Mini a 0.40\$/M. Sur 22 000 mails/mois, la difference est de quelques euros. En contrepartie : debug supplementaire, qualite inferieure, risque Preview. Si le budget est vraiment contraint, GPT-4.1 Mini est le meilleur choix budget — pas Gemini.

9. Les deux options stratégiques

Deux options. Pas trois. **Le statu quo n'est pas une option** — c'est une décision de ne pas décider, et c'est la plus coûteuse.

Option A (recommandée) : Reorganiser et investir dans les produits clients

Reorganiser les ressources internes pour que l'IA devienne une priorité, pas un sujet secondaire. Nommer un Responsable IA dédié. Prioriser NeoMail (le produit que les clients demandent). Débloquer les goulots (accès admin, maquettes, QA).

- Raphaël en Responsable IA dédié — actuellement à 50K+bonus pour un poste dev, réévaluation nécessaire (65-75K EUR, marche Lyon Lead IA 2026)
- Jérôme recentre sur les projets IA avec accès admin complets (dev + test + prod) — actuellement payé comme dev, réévaluation à prévoir si rôle élargi (52-60K EUR)
- +1 dev supplémentaire polyvalent équipe Claude Code (42-50K EUR)
- +1 UX/designer dédié IA — c'est LE chaînon manquant (40-48K EUR, ou réaffectation interne)
- QA : temps dédié pour les produits IA ou testeur supplémentaire
- Switcher vers Claude Sonnet 4.6 + Haiku (surcout ~30-50 EUR/mois)

Investissement supplémentaire : ~82-100K EUR/an. **Revenu potentiel** : 60-120K EUR/an sur 50 clients. **Time to market NeoMail** : 2-3 mois.

Stratégie cle : même à 4, on ne concurrence pas 10-50 personnes. La stratégie doit être de faire UNE chose qu'eux ne peuvent pas faire : l'intégration native aux données métier Loji. C'est le seul avantage que ni Bellman, ni Genius, ni Gemini ne peuvent reproduire.

Option B (plan de repli) : Pivoter vers MCP + formation multi-plateforme

Neoteem s'adapte à la plateforme du client et fournit l'expertise métier immobilier + IA :

- Client sur Claude : MCP Loji + skills Cowork
- Client sur OpenAI : MCP Loji + GPTs custom (OpenAI supporte aussi le MCP)
- Client sur Gemini : formation à utiliser Gemini dans Gmail/Drive + Gems custom (pas de MCP)
- Formation multi-plateforme adaptée au choix du client

Limites sérieuses :

- Gemini ne supporte pas le MCP : les clients sur Gemini (la majorité) n'ont PAS accès aux données Loji
- Ne construit pas de produit propriétaire — aucune barrière à l'entrée
- Cannibalisation des futurs produits : si les clients s'habituent à utiliser Gemini directement, ils ne paieront jamais pour NeoMail
- Gemini est déjà dans Gmail — former les clients à utiliser ce qu'ils ont déjà = faible valeur perçue

Avis Claude : *L'option B est un plan de repli si la direction refuse de reorganiser. C'est mieux que ne rien faire. Mais ça ne construit pas d'avenir. Voir la section 15 pour le verdict final détaillé.*

10. L'équipe nécessaire et la reorganisation

Il ne s'agit pas forcément de recruter. Neoteem a 20+ personnes. La première action est de reorganiser.

Role	Qui	Action requise	Cout
Responsable IA (dedie, full-time)	Raphael PICARD	Evolution du poste actuel (dev a 50K+bonus). Pilotage roadmap IA, arbitrage priorites, coordination equipe, veille techno. Pouvoir de decision. Le switch de poste justifie une reevaluation salariale.	Actuel : 50K+5K Cible : 65-75K (marche Lyon Lead IA 2026)
Dev polyvalent IA (binome/bras droit)	Jerome	Bras droit technique depuis le debut. Profil rare : front + back + DevOps + IA. Recentrer sur les projets IA. DEBLOQUER SES ACCES ADMIN (test + prod). Actuellement paye comme dev — reevaluer si role elargi.	Actuel : ~poste dev Cible : 52-60K (marche Lyon fullstack+DevOps +IA)
Dev IA supplementaire	A ajouter (ou reaffecter)	Profil polyvalent back/front equipe Claude Code. Un dev avec IA produit comme 2-3 devs classiques.	42-50K (recrutement ou interne)
UX/Designer dedie IA	Reaffecter UX existant ou recruter	LE chainon manquant. Sans maquettes, pas de front. Sans front, pas de produit. Priorite = projets IA.	40-48K (ou reffect. interne)
QA dedie IA	Temps dedie QA existant	Les QA actuels sont surcharges. Soit un QA dedie IA, soit du temps protege contractuellement.	Reaffect. (0 EUR)

Le minimum absolu pour debloquer la situation : donner a Jerome les acces admin, reaffecter un UX sur les maquettes IA, et proteger du temps QA. Ca ne coute rien — c'est de la reorganisation. L'investissement reel : 1 dev + potentiellement 1 UX = 82-100K EUR/an.

Note sur le poste de Responsable IA et la revalorisation salariale

Situation contractuelle actuelle : Raphael est embauche comme Ingenieur IA (CDI SYNTEC cadre 3.1 coeff 170) a 50 004 EUR brut/an + 5 000 EUR variable conditionne a des livrables specifiques (montee en competence, NeoChat, NeoDoc). Ce salaire est calibre pour un poste de developpeur IA — et il est correct pour ce poste.

Le probleme : en 6 mois, le perimetre reel a explose bien au-dela de la fiche de poste. Raphael a concu l'architecture back2.0 (Bun/Hono/Drizzle), construit 3 apps + 3 MCP + le neoteem-brain (682 notes metier), cree des skills Cowork pour le support et la direction, fait du benchmark concurrentiel, evalue les modeles LLM, forme des collegues, et produit ce dossier strategique. Ce n'est plus le travail d'un Ingenieur IA — c'est le travail d'un Lead/Responsable IA.

Si la direction souhaite officialiser ce role (pilotage roadmap IA, arbitrage priorites, coordination equipe, pouvoir de decision), c'est un changement de poste qui justifie une reevaluation salariale vers 65-75K EUR (fourchette marche Lyon 2026 pour un Lead/Responsable IA). On ne peut pas demander a quelqu'un de faire le travail d'un Responsable IA au salaire d'un developpeur.

Point d'attention : le variable actuel (5 000 EUR) est conditionne a des livrables NeoChat et NeoDoc. Si Raphael consacre 80% de son temps a des missions plus strategiques (architecture, brain, formations, ce dossier), il risque de ne pas atteindre ses objectifs contractuels — alors qu'il fait des choses objectivement plus impactantes pour Neoteem. Le perimetre du variable doit etre realigne sur le perimetre reel.

Meme logique pour Jerome : s'il est officiellement recentre sur un role elargi IA (front + back + DevOps + IA avec acces admin complets), son poste doit etre reevalue en consequence.

Avis Claude : Avis Claude — soyons francs : Raphael est un profil rare qui combine code, architecture, ecosysteme IA (LLM, MCP, agents) et vision produit/business. En 6 mois, a 2 personnes, l'equipe IA a construit plus que ce que la plupart des equipes de 5-10 produisent. C'est factuel, pas du compliment. La multiplicité des projets (neoteem-brain, back2.0, skills Cowork, formations...) n'est pas un manque de priorisation — c'est l'utilisation intelligente du temps mort pendant que NeoMail est bloqué (pas d'accès admin, pas de maquettes, pas de QA). Quand le produit prioritaire ne peut pas avancer, un bon profil ne reste pas les bras croisés : il construit les fondations qui serviront quand ça débloquera. Des alertes ont déjà été remontées à la direction par écrit — le problème n'est pas un manque de communication, c'est un manque de réception. Son vrai défaut : Raphael est trop direct et pas assez politique. Il dit les choses comme elles sont, sans les enrober. Dans un contexte technique, c'est une qualité. Dans un contexte corporate ou la direction hésite, ça peut braquer au lieu de convaincre. Ce dossier existe en partie pour compenser ce défaut — poser les faits de manière structurée plutôt que les dire à chaud. La direction a deux choix : reévaluer le poste et le salaire, ou accepter que Raphael revienne à son périmètre contractuel (dev IA uniquement). Les deux sont légitimes. Ce qui ne l'est pas, c'est de demander le travail d'un Responsable IA au tarif d'un dev.

11. Modele economique : comment faire payer les clients

Aujourd'hui, il n'existe pas de strategie economique claire pour monetiser les produits IA. NeoChat, NeoMail, NeoDoc sont developpes sans savoir comment les faire payer. C'est un probleme fondamental : sans modele economique, il n'y a pas de produit.

Business Plan — Option A : Produits IA integres dans Loji

Source de revenu	Prix	Benchmark marche
NeoMail integre (abo mensuel)	29-49 EUR/user/mois ou 99-199 EUR/cabinet/mois	Genius Immo : 49 EUR/user/mois Bellman : inclus dans le logiciel
NeoChat integre	Inclus ou 19-39 EUR/user/mois	Chatbots SaaS : 50-500 EUR/mois
NeoDoc integre	Inclus ou au volume	NotebookLM : gratuit (menace)
Setup / onboarding	500-1 500 EUR (one-shot)	Standard SaaS B2B

Projection revenus Option A — 30 clients en 12 mois

Poste	Calcul	Annuel
Abo NeoMail (30 x 249 EUR/mois)	30 x 249 x 12	89 640 EUR
Setup onboarding (30 x 1 000 EUR)	30 x 1 000	30 000 EUR
Couts API tokens (30 x 220 EUR/mois)	30 x 220 x 12	- 79 200 EUR
Couts infra (Cloud Run)	~100 EUR/mois x 12	- 1 200 EUR
REVENU NET ANNUEL (avant salaires)		39 240 EUR

Note volumes corriges : 1 000 mails/jour par cabinet (200 mails/jour x 5 gestionnaires), prix ajuste a 249 EUR/cabinet/mois (benchmark : Genius = 49 EUR x 5 = 245 EUR). A ce volume, les couts tokens representent ~220 EUR/mois/client — la marge sur les tokens seuls est faible (~12%), mais le setup + l'effet scale a 50-100 clients change la donne.

Avis Claude : Avec les volumes corriges (1 000 mails/jour), les couts tokens sont plus eleves que l'estimation initiale. A 249 EUR/mois, la marge par client sur les tokens seuls est etroite (~29 EUR). Mais le modele economique SaaS fonctionne par effet de scale : a 50 clients, le revenu annuel passe a ~149 400 EUR avec des couts tokens de ~132 000 EUR + 30K infra = marge de ~17K avant salaires + 50K setup. A 100 clients, c'est ~298 800 EUR de revenus avec une marge de ~100K+ (l'infra ne scale pas lineairement). La cle : optimiser les couts tokens (prompt caching, batch API) et viser 50+ clients rapidement. Une alternative : augmenter le prix a 349 EUR/cabinet/mois (les concurrents justifient ce prix par le gain de 10h/semaine).

Business Plan — Option B : MCP + Formation multi-plateforme

Poste	Calcul	Annuel
Abo MCP (30 cabinets x 40 EUR/mois)	30 x 40 x 12	14 400 EUR

Poste	Calcul	Annuel
Formations initiales (30 x 1 500 EUR)	30 x 1 500	45 000 EUR
Skills/GPTs custom (15 x 1 000 EUR)	15 x 1 000	15 000 EUR
Maintenance skills (15 x 50 EUR x 12)	15 x 50 x 12	9 000 EUR
Couts (infra MCP + temps formateur)	~200 EUR/mois x 12	- 2 400 EUR
REVENU NET ANNUEL		~81 000 EUR

Comparaison structurelle des deux options

Critere	Option A (produit SaaS)	Option B (MCP + formation)
Revenu a 30 clients	~39K EUR net + 30K setup = ~69K EUR an 1	~81K EUR net
Revenu a 100 clients	~270K+ EUR/an recurrent	Plafonne (formations ne scalent pas)
Type de revenu	Recurrent, previsible (SaaS)	Mixte (abo faible + formations ponctuelles)
Scalabilite	Elevee (SaaS sans effort par client)	Faible (formateur par session)
Actif construit	Produit propriétaire	Aucun (conseil/formation)
Time to market	2-3 mois	Semaines
Investissement equipe	82-100K EUR/an	Faible
Risque principal	Direction refuse de reorganiser	Cannibalisation des futurs produits

12. Grille de prix complete — comparatif modeles IA (mai 2026)

Tous les prix en USD par million de tokens. 1 token ~ 4 caracteres ~ 0.75 mot FR. Un mail de 200 mots ~ 270 tokens. Un prompt systeme de 1 000 mots ~ 1 350 tokens.

Modele	Input \$/M	Output \$/M	Cache	GA?	Forces	Faiblesses
Claude Opus 4.7	5.00	25.00	0.50	GA	Meilleur raisonnement	Tres cher
Claude Sonnet 4.6	3.00	15.00	0.30	GA	Meilleur qualite/prix Redaction FR excellente Tool calling fiable	Plus cher que GPT-4.1 Mini
Claude Haiku 4.5	1.00	5.00	0.10	GA	Rapide, classification	Redaction FR limitee
GPT-4.1	2.00	8.00	0.50	GA	Bon tool calling	Redaction FR moyenne
GPT-4.1 Mini	0.40	1.60	~0.04	GA	Ultra pas cher Classification ideale	Qualite redaction limitee
GPT-4.1 Nano	0.10	0.40	~0.01	GA	Le - cher du marche	Taches simples uniqmt
Gemini 2.5 Flash	0.30	2.50	Oui	GA	Tres pas cher, stable	Tool calling moyen Redaction FR inferieure
Gemini 3 Flash	0.50	3.00	Oui	Preview	Benchmarks forts	PAS DE SLA Peut changer sans preavis

Avis Claude : Recommandation : **Claude Sonnet 4.6** pour la redaction et le raisonnement (brouillons mail, chatbot), **GPT-4.1 Mini** pour la classification haute frequence (triage mail, triage tickets). C'est le combo le plus fiable du marche en 2026. Gemini 3 Flash est en Preview — pas un modele de production. L'economie realisee en choisissant Gemini est de quelques euros par mois par client. En contrepartie : tool calling moins fiable, redaction FR inferieure, pas de SLA.

13. Coûts détaillés par produit

NeoMail — 1 000 mails/jour, 5 gestionnaires, 22 jours ouvrables

Pipeline par mail : classification (~500 tok in + ~50 tok out, modèle léger) + brouillon réponse (~2 500 tok in + ~400 tok out, modèle qualité).
Prompt système (~1 500 tok) cache à 90%.

Classif.	Brouillon	Coût classif.	Coût brouillon	TOTAL/mois	Qualité FR
GPT-4.1 Mini	Claude Sonnet 4.6	\$6	\$208	~\$214 (~196 EUR)	Excellente
Haiku 4.5	Sonnet 4.6	\$17	\$208	~\$225 (~206 EUR)	Excellente
GPT-4.1 Mini	GPT-4.1	\$6	\$131	~\$137 (~125 EUR)	Moyenne
Gemini 2.5 Flash	Gemini 2.5 Flash	\$6	\$30	~\$36 (~33 EUR)	Inférieure

Avis Claude : Le combo recommande (GPT-4.1 Mini + Claude Sonnet) coûte ~214\$/mois (~196 EUR) par cabinet pour 1 000 mails/jour. C'est le prix de la qualité. Si on facture 249 EUR/mois, la marge tokens est de ~53 EUR (~21%). À 349 EUR/mois (justifiable par le gain de 10h/semaine revendiqué par Genius), la marge passe à 153 EUR (~44%). L'argument 'l'IA coûte cher' ne tient pas — le vrai coût c'est l'équipe pour développer le produit.

NeoChat — 100 conversations/jour, 3-5 tours

Modèle	TOTAL/mois	Qualité
Claude Sonnet 4.6	~\$144 (~132 EUR)	Excellente
Claude Haiku 4.5	~\$48 (~44 EUR)	Bonne
GPT-4.1 Mini	~\$18 (~16 EUR)	Correcte
Gemini 2.5 Flash	~\$17 (~16 EUR)	Moyenne

Avis Claude : NeoChat coûte entre 17\$ et 144\$/mois par cabinet. Le vrai problème n'est pas le coût — c'est l'utilité. Après 5 mois en pilote, personne n'a confirmé que les copropriétaires l'utilisent. Avant d'investir davantage, il faut demander aux clients pilotes.

NeoDoc — 50 requêtes/jour, 5 utilisateurs

Vertex AI Search ~2.75\$/mois + LLM ~0.50-10\$/mois = **total 1-11\$/mois** (~1-10 EUR).

Avis Claude : NeoDoc coûte quasi rien en tokens. La question stratégique : les clients peuvent utiliser Google NotebookLM gratuitement pour interroger leurs documents. NeoDoc n'a de valeur que s'il intègre les données Loji dans les réponses — ce que NotebookLM ne fait pas.

Triage support interne (250 tickets/jour)

Cout API (GPT-4.1 Mini) : ~5\$/mois vs ~500 EUR/mois d'abonnement Team actuel. Economie potentielle : ~496 EUR/mois, soit ~5 950 EUR/an.

Synthese : cout total par cabinet (approche recommandee)

Produit	Cout/mois	Prix facture	Marge
NeoMail (1000 mails/j)	~196 EUR	249-349 EUR	21-44%
NeoChat (100 conv/j)	~44 EUR	Inclus ou 49 EUR	10-100%
NeoDoc (<500 docs)	~10 EUR	Inclus ou 29 EUR	66-100%
Pack complet	~250 EUR	249-349 EUR/cabinet	0-28% (tokens seuls)

Avis Claude : Avec les volumes corriges (1 000 mails/jour), le pack complet coute ~250 EUR/mois en tokens. A 249 EUR/mois, la marge tokens est quasi nulle — il faut viser 349 EUR/cabinet/mois ou optimiser les couts (prompt caching agressif, batch API pour les traitements non-temps-reel). Le setup (500-1 500 EUR) et la retention long-terme sont essentiels pour la rentabilite. A 100 clients, l'infra mutualisee et le setup amortissent largement les couts.

14. Recommandations et plan d'action

Decisions immediates (cout zero — reorganisation)

1. Donner a Jerome les acces admin sur tous les environnements. C'est le blocage le plus absurde et le plus facile a resoudre.
2. Affecter un UX aux maquettes NeoMail. 1 semaine de travail UX debloque 3 mois de blocage.
3. Proteger du temps QA pour les produits IA. Definir un sprint QA dedie.
4. Collecter formellement les besoins clients. Interroger 5-10 clients pilotes. Documenter.
5. Abandonner l'idee de recreer Gmail. Pivoter vers add-on Gmail + panneau lateral Loji.

Decisions strategiques (investissement)

6. Nommer un Responsable IA dedie avec pouvoir de decision sur les priorites.
7. Prioriser NeoMail. Le backend est pret. La fenetre face a Gemini est etroite.
8. Switcher le LLM vers Claude/GPT pour les produits clients. Surcout : ~30-50 EUR/mois. Gain : fiabilite.
9. Diagnostiquer NeoChat (5 mois pilote, utilite non confirmee — pivoter ou continuer ?).
10. Questionner NeoDoc avant de le developper (NotebookLM = alternative gratuite).
11. Mettre en place des KPI produit des le premier jour (DAU, MAU, NPS, MRR).

Timeline recommandee

Quand	Action	Resultat
Semaine 1	Acces admin Jerome. UX sur maquettes NeoMail. Lancer enquete clients (5-10 interviews). Decider add-on Gmail vs client mail.	Blocages leves. Donnees clients.
Semaine 2-3	Maquettes NeoMail finalisees. Jerome attaque le front. Switcher LLM vers Claude Sonnet.	Dev front lance.
Mois 1-2	Nommer Responsable IA. +1 dev IA. Front NeoMail en cours. QA dedie.	Equipe IA structuree.
Mois 2-3	NeoMail en beta client. Premiers retours. Iteration.	Premier produit IA en production client.
Mois 3-6	Diagnostic NeoChat. Lancer NeoDoc si valide. Mesurer KPI.	Suite produit IA mesuree.

15. Verdict final de Claude : Option A vs Option B

Ce qui suit est mon avis honnête, sans filtre, en tant qu'IA ayant analysé l'ensemble du dossier : données techniques, benchmark concurrentiel, coûts réels, et contexte organisationnel de Neoteem.

Verdict : L'option A est le seul chemin vers un avantage concurrentiel durable.

Mais elle ne fonctionne que si la direction accepte trois choses :

- 1) Reorganiser (accès admin, UX, QA — coût zéro)
- 2) Nommer un Responsable IA avec pouvoir de décision
- 3) Abandonner l'idée de recréer Gmail

Si la direction refuse ces trois conditions, l'option B est infiniment mieux que le statu quo. Le statu quo est la pire option.

Pourquoi Option A

L'option A est la seule qui construit un actif propriétaire. Le SaaS IA intégré dans un ERP métier, c'est une barrière à l'entrée : ni Bellman, ni Genius, ni Gemini ne peuvent reproduire l'intégration native aux données Loji. C'est le seul avantage concurrentiel de Neoteem. L'option B le gaspille.

A 50 clients (objectif réaliste à 18 mois), l'option A génère du revenu récurrent prévisible qui couvre l'équipe IA. A 100 clients, elle dégagera une marge significative. L'option B plafonne car les formations ne scalent pas — chaque nouveau client nécessite du temps formateur.

Pourquoi Option B est un plan de repli acceptable

L'option B génère du revenu en semaines (~81K EUR/an sur 30 clients) avec un investissement quasi nul. C'est mieux que ne rien faire pendant 6 mois de plus. Mais elle ne construit rien : pas de produit propriétaire, pas de barrière à l'entrée, pas de scalabilité. N'importe quel consultant IA peut faire pareil.

Le risque le plus grave de l'option B : la cannibalisation. Si les clients s'habituent à utiliser Gemini/Claude/GPT directement avec le MCP Loji, ils ne paieront jamais pour un NeoMail intégré. C'est tuer ses propres futurs produits.

La vraie question que ce bilan pose

Est-ce que Neoteem veut être un éditeur de logiciel IA (option A) ou un cabinet de conseil/formation IA pour syndicats (option B) ?

Les deux sont viables. Les deux génèrent du revenu. Mais ce ne sont pas le même métier. Un éditeur de logiciel construit un actif qui prend de la valeur. Un cabinet de conseil vend du temps. A 20+ personnes, Neoteem a la taille d'un éditeur — mais se comporte comme un cabinet qui hésite.

Les trois erreurs à ne pas commettre

1. **Ne pas decider.** Le statu quo est la pire option. Chaque mois d'indecision est un mois offert a Bellman (3 000 employes + Bpifrance), Genius (10 personnes, deja en prod), et Google (Gemini dans Gmail). Le capital technique construit par Raphael et Jerome perd de la valeur chaque jour ou il ne genere pas de revenu.
2. **Recreer Gmail.** C'est un projet pharaonique impossible a 2-4 personnes. Google a des milliers d'ingenieurs sur Gmail. La valeur de NeoMail est le contexte metier, pas l'interface mail. Add-on Gmail + panneau lateral = 2-3 mois. Client mail complet = 12-18 mois minimum, probablement jamais fini.
3. **Economiser sur les tokens au detriment de la qualite.** La difference entre Gemini et Claude/GPT est de quelques euros par mois par client. En contrepartie : des semaines de debug, une qualite percue inferieure par les clients, et un modele en Preview sans SLA. Ce n'est pas une economie — c'est un risque.

Le mot de la fin

Neoteem a un capital technique IA que peu de startups de 20 personnes possedent. 3 apps, 3 MCP custom, un vault de 682 notes metier, des outils de productivite pour toute l'equipe. Ce capital a ete construit par 2 personnes en 6 mois. C'est remarquable.

Mais un capital technique qui ne genere pas de revenu est un cout, pas un actif. Pour le transformer en produits clients, il faut des conditions que Neoteem ne reunit pas aujourd'hui : un responsable IA dedie, des maquettes, des acces admin, du temps QA, et une ecoute structuree des clients.

Ces conditions ne coutent presque rien a reunir. La plupart sont de la reorganisation interne.

La question n'est pas 'est-ce qu'on peut se le permettre ?'. La question est :

Est-ce qu'on peut se permettre de NE PAS le faire, alors que Bellman, Genius et Gemini avancent chaque jour ?

Sources : Audit technique des projets Neo* (Claude Code, mai 2026). Donnees publiques concurrents (Septeo/ZoomInfo, genius.immo, reemia.ai, LinkedIn). Benchmarks LLM 2026 (Seyos, Glassdoor, Coursera). Annonces Google (Gmail Gemini, jan-fev 2026). Pricing pages Anthropic, OpenAI, Google Cloud (mai 2026). 6+ mois d'experience sur l'architecture IA de Neoteem. Avis strategiques de Claude (Anthropic).